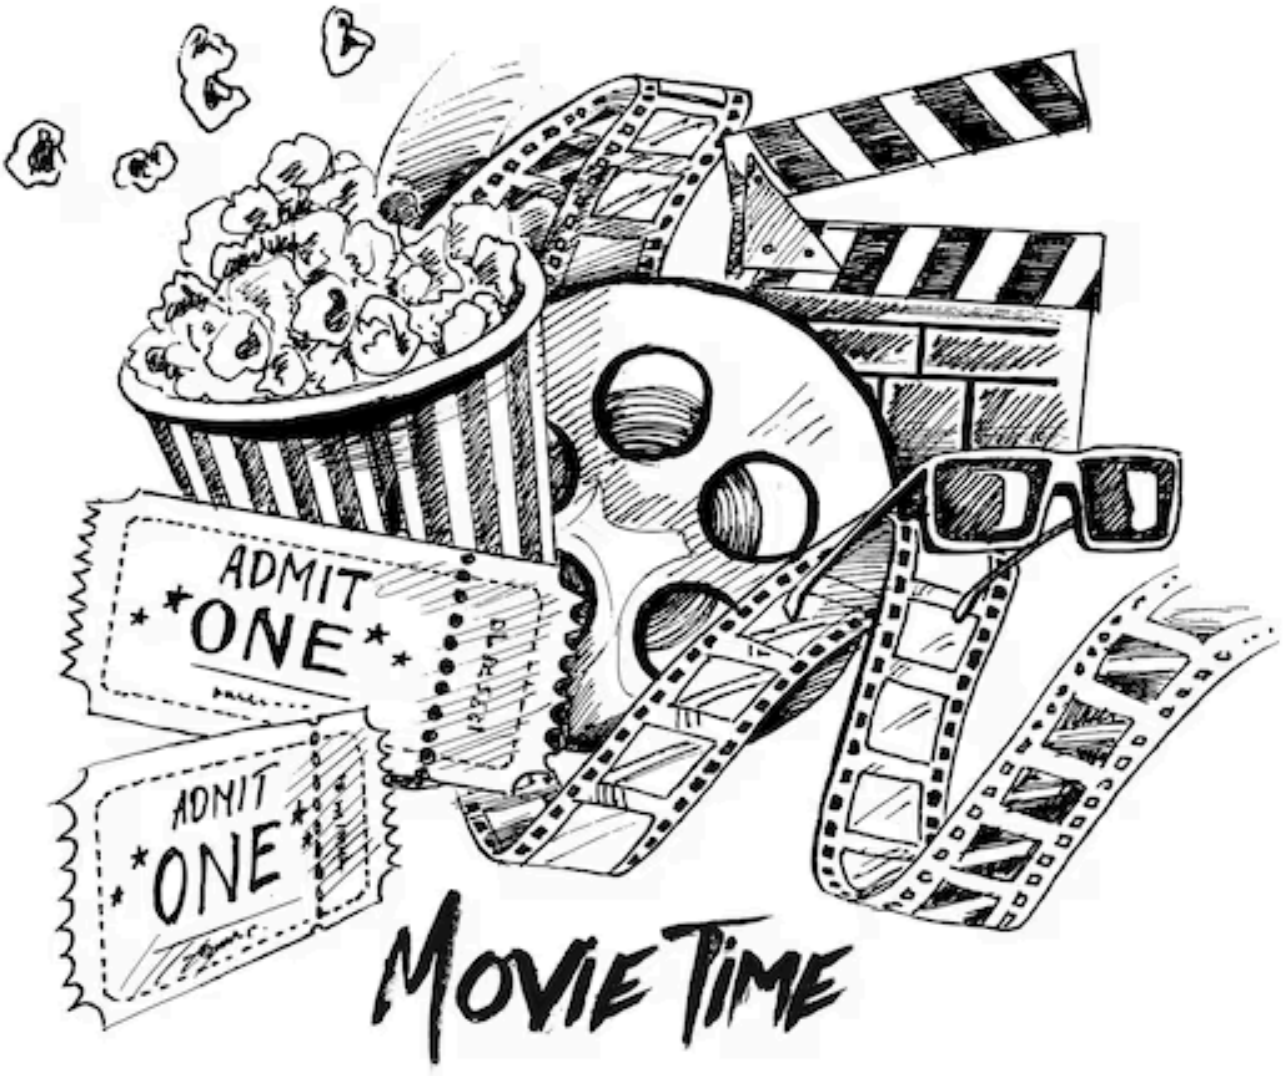
Sujet SAÉ S3.01 − Application de Films

Groupe D : Hugo Ribeiro, Adam Benelcadi,
Ali Ouahabi,Achour Hamou Yahia



Livrable 5:
Analyse et modélisation de la base de données, automatisation de la collecte et du chargement des données, et évaluation des performances.

Groupe D:
- Hugo Ribeiro
- Adam Benelcadi
- Ali Ouahabi
- Achour Hamou Yahia

1. Introduction :

Dans le cadre de notre projet Movie Time, nous devons mettre en place une base de données permettant de stocker et d'exploiter les informations cinématographiques fournies par IMDb. Ce cinquième livrable consiste à analyser les sept fichiers TSV d'IMDb, à concevoir un modèle UML et un schéma relationnel, puis à créer les tables correspondantes dans MariaDB.

Nous allons également réaliser des scripts shell pour automatiser le téléchargement des données les plus récentes ainsi que leur chargement et leur remplacement dans notre base MariaDB, exécutée sous Docker. Enfin, nous effectuerons des tests pour vérifier le bon fonctionnement de ces opérations et mesurer leurs performances, notamment les temps de téléchargement et d'importation.

2. Analyse des données IMDb :

2.1. Présentation des fichiers IMDb :

Pour notre projet, nous utilisons sept fichiers fournis par IMDb au format TSV, compressés en `.gz`. Chaque fichier contient un type d'information précis sur les œuvres cinématographiques et les personnes qui y participent.

Fichier	Description
title.basics	Informations générales sur les films et séries : titres, années, durées et genres.
title.akas	Titres alternatifs selon les pays et les langues.
name.basics	Informations sur les acteurs, réalisateurs et autres professionnels.

title.crew	Réalisateurs et scénaristes associés aux œuvres.
title.episode	Liens entre les séries et leurs épisodes.
title.principals	Participants aux œuvres et leurs rôles.
title.ratings	Notes moyennes et nombres de votes des œuvres.

Ces fichiers sont complémentaires : par exemple, les informations générales d'un film sont dans *title.basics*, ses participants dans *title.principals* et sa note dans *title.ratings*.

Certaines colonnes contiennent plusieurs valeurs séparées par des virgules, comme **genre** et **directors**. Les valeurs manquantes sont indiquées par `\N`. Ces particularités devront être prises en compte lors de la création de notre base MariaDB.

2.2. Analyse des données et des relations entre les fichiers :

Les fichiers IMDb sont reliés grâce à deux identifiants principaux :

- **tconst** : identifiant unique d'une œuvre (film, série ou épisode).
- **nconst** : identifiant unique d'une personne (acteur, réalisateur, etc.).

Le fichier *title.basics* centralise les œuvres et les relie aux titres alternatifs (*title.akas*), aux notes (*title.ratings*) et aux participants (*title.principals*).

Le fichier *name.basics* référence les personnes, associées aux œuvres via *title.principals* et *title.crew*. Enfin, *title.episode* relie chaque épisode à sa série grâce à **parentTconst**.

Ces relations serviront à définir les **clés primaires et étrangères** de notre base MariaDB.

3. Modélisation de la base de données MariaDB :

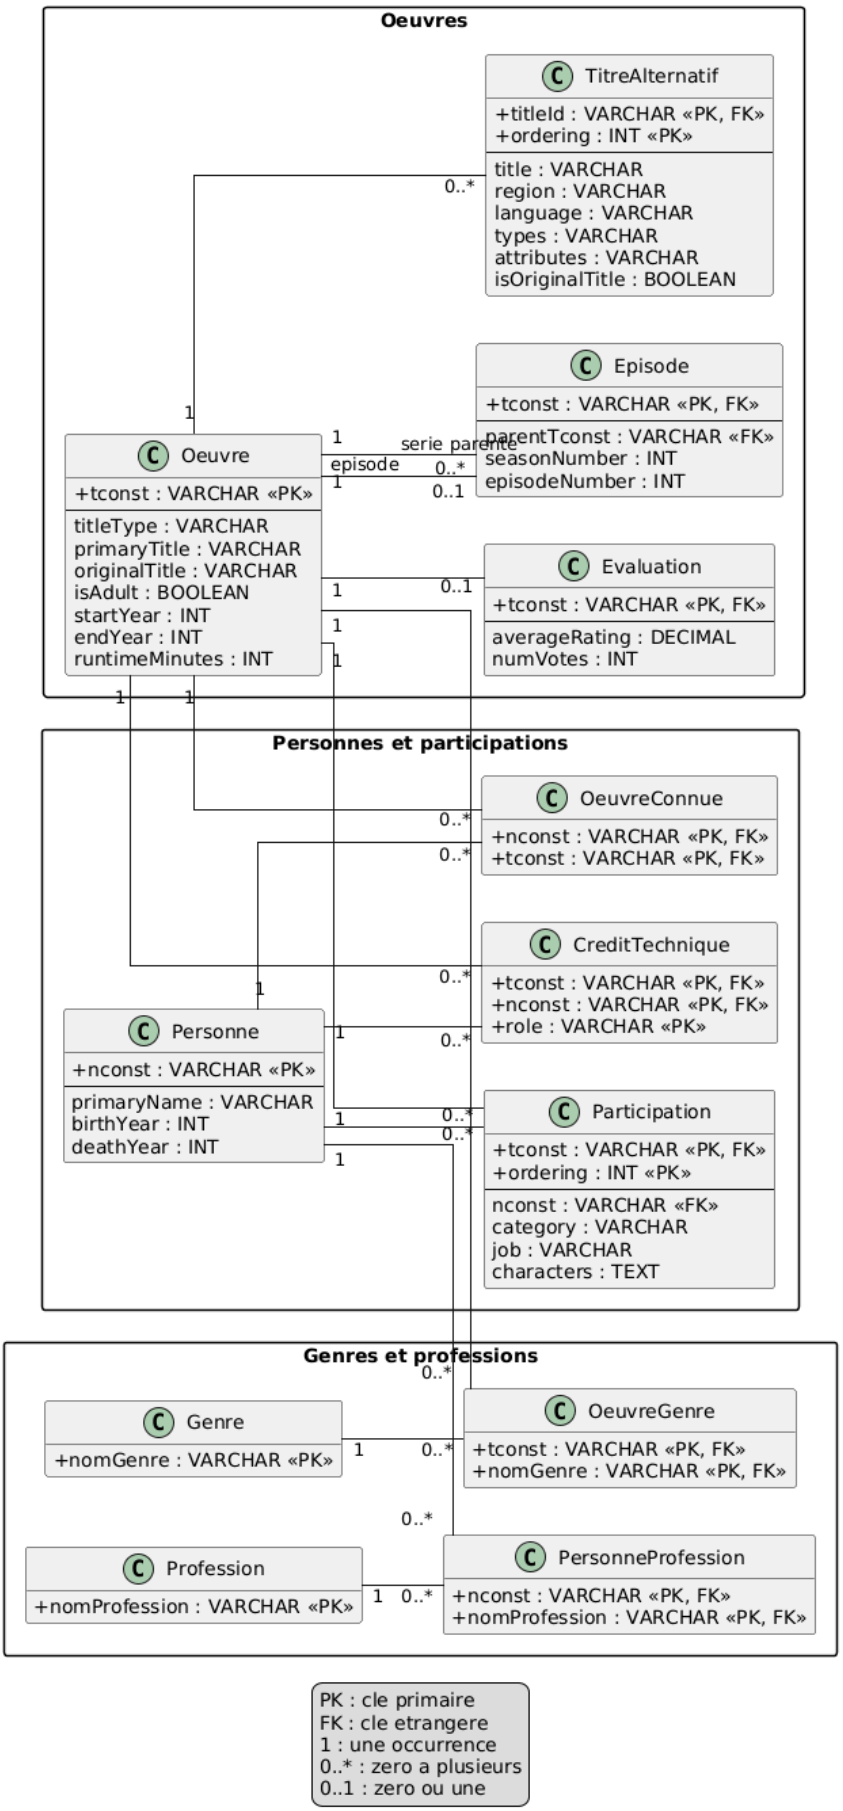
3.1. Diagramme UML et justification des choix de modélisation :

Nous avons utilisé **PlantUML** pour réaliser le diagramme UML de notre base de données à partir des sept fichiers IMDb.

Le diagramme comprend **12 tables**, réparties en trois groupes : les œuvres, les personnes et participations, ainsi que les genres et professions. Les tables principales `Oeuvre` et `Personne` sont reliées aux autres par des clés primaires (PK) et étrangères (FK).

Des tables d'association, comme `Participation` et `OeuvreGenre`, permettent de gérer les relations entre plusieurs éléments. Cette organisation limite les répétitions et facilite les recherches dans MariaDB.

Diagramme UML de la base IMDb



3.2. Schéma relationnel et scripts SQL de création des tables sous MariaDB :

À partir du diagramme UML réalisé avec PlantUML, nous avons défini un schéma relationnel composé de **12 tables**. Chaque table possède une clé primaire (PK) et les clés étrangères (FK) permettent d'établir les relations entre les données.

Schéma relationnel :

Table	**Attributs**
Oeuvre	tconst (PK), titleType, primaryTitle, originalTitle, isAdult, startYear, endYear, runtimeMinutes
Personne	nconst (PK), primaryName, birthYear, deathYear
TitreAlternatif	titleId (PK, FK), ordering (PK), title, region, language, types, attributes, isOriginalTitle
Evaluation	tconst (PK, FK), averageRating, numVotes
Episode	tconst (PK, FK), parentTconst (FK), seasonNumber, episodeNumber
Participation	tconst (PK, FK), ordering (PK), nconst (FK), category, job, characters
Genre	nomGenre (PK)
OeuvreGenre	tconst (PK, FK), nomGenre (PK, FK)
Profession	nomProfession (PK)
PersonneProfession	nconst (PK, FK), nomProfession (PK, FK)
CreditTechnique	tconst (PK, FK), nconst (PK, FK), role (PK)
OeuvreConnue	nconst (PK, FK), tconst (PK, FK)

Les tables d'association, comme **OeuvreGenre**, **PersonneProfession** et **CreditTechnique**, permettent de gérer les relations plusieurs-à-plusieurs et de limiter les répétitions de données.

Pour créer ces tables dans **MariaDB**, nous utilisons un script *schema.sql*, placé dans le dossier *database/*. Il définit les types de données, les clés primaires et étrangères ainsi que les contraintes nécessaires.

4. Automatisation de la récupération et de l'importation des données :

4.1. Scripts shell de téléchargement des données IMDb :

Pour récupérer les données IMDb, nous utilisons un script Bash nommé *download_imdb.sh* qui se trouvent dans le dossier scripts/ . Il télécharge automatiquement les sept fichiers TSV compressés depuis le site officiel d'IMDb.

Les fichiers sont enregistrés dans le dossier *database/imports/*. Le script permet de récupérer les versions les plus récentes sans effectuer chaque téléchargement manuellement.

4.2. Scripts shell de chargement et de remplacement des données dans MariaDB:

Tous les scripts ci-dessous sont dans scripts/. Ils chargent les fichiers IMDb dans les 12 tables MariaDB.

• _import_common.sh : fonction commune : importation par lots de 20 000 lignes.
• import_oeuvres.sh : importe les films, séries et épisodes.
• import_personnes.sh : importe les personnes IMDb.
• import_genres.sh : ajoute les genres.
• import_professions.sh : ajoute les professions.
• import_oeuvre_genres.sh : associe les œuvres à leurs genres.
• import_personne_professions.sh : associe les personnes à leurs professions.
• import_evaluations.sh : importe les notes et votes.
• import_titres_alternatifs.sh : importe les titres selon les pays et langues.
• import_episodes.sh : relie les épisodes aux séries.
• import_participations.sh : importe les acteurs et autres participants.
• import_credits_techniques.sh : importe les réalisateurs et scénaristes.
• import_oeuvres_connues.sh : associe les personnes à leurs œuvres connues.
• remplacer_imdb.sh : prépare le remplacement complet des données IMDb en créant une nouvelle base et en lançant les scripts d'importation. Le remplacement n'a pas pu être testé entièrement à cause du manque d'espace disque.

Les scripts lisent les fichiers compressés, préparent les colonnes avec **awk** et chargent les données dans MariaDB. Les lots temporaires sont supprimés après chaque chargement afin d’éviter de remplir inutilement le disque dur.

5. Tests et performances :

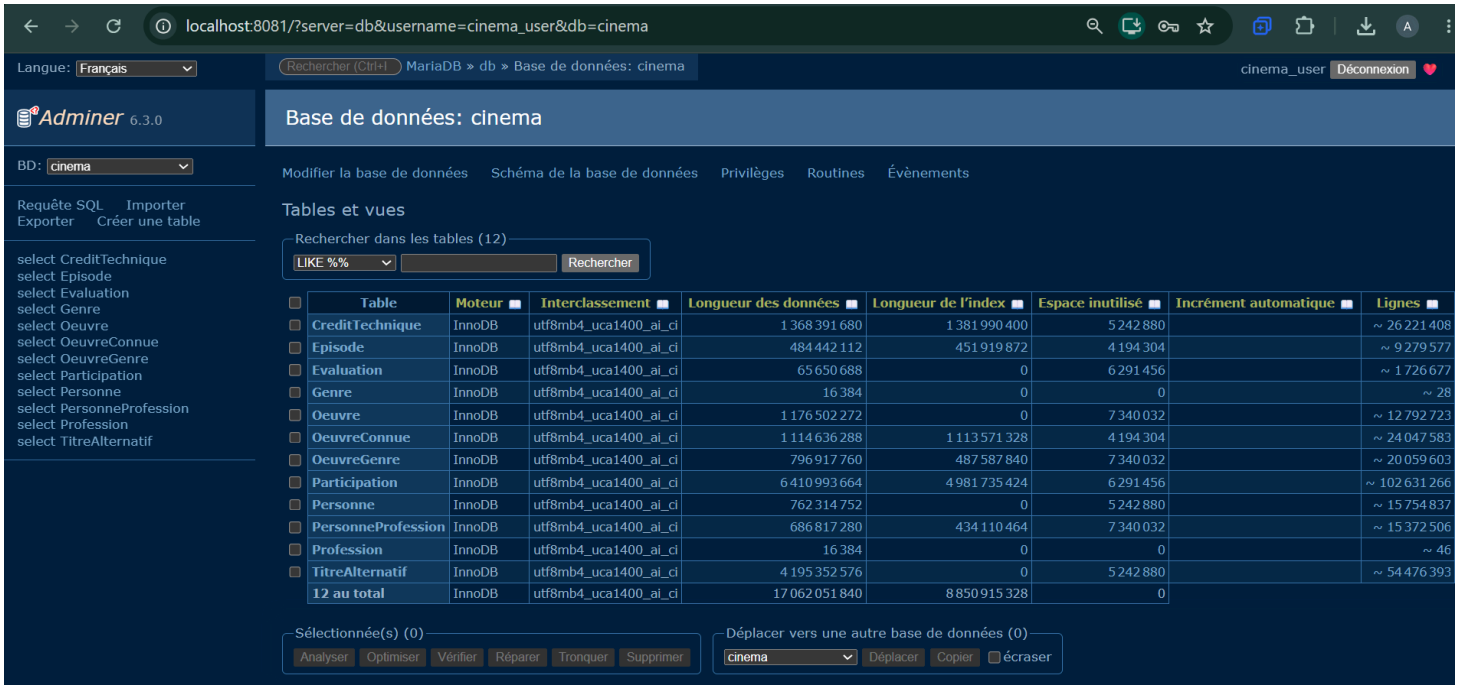
5.1. Vérification des tables et des données avec Adminer :

Nous avons utilisé Adminer pour vérifier que les données IMDb ont bien été importées dans notre base MariaDB **cinema**.

Comme le montre la capture d'écran, les 12 tables sont présentes et contiennent des données. Par exemple, la table **Oeuvre** contient 12 933 095 lignes, la table **Personne** contient 15 789 525 lignes et la table **Genre** contient 28 lignes.

Nous avons également exécuté des requêtes SQL pour vérifier le nombre exact de lignes dans ces trois tables. Les nombres affichés directement dans Adminer sont des estimations.

La base occupe environ 24,13 Go de données et d'index.



5.2. Mesure des temps de téléchargement, d'importation et de remplacement des données :

Téléchargement :

Nous avons mesuré le temps de téléchargement des sept fichiers IMDb avec la commande *time bash scripts/download_imdb.sh*.

Le téléchargement s'est terminé en **10 minutes et 47 secondes**, soit environ 647 secondes.

Importation :

Pour mesurer le temps de chargement des données IMDb, nous utilisons la commande **time** autour de l'exécution des 12 scripts d'importation.

```
Benelcadi@DESKTOP-D321M1B UCRT64 ~/Desktop/S3.01-groupe-D (main)
$ time {
  bash scripts/import_oeuvres.sh &&
  bash scripts/import_personnes.sh &&
  bash scripts/import_genres.sh &&
  bash scripts/import_professions.sh &&
  bash scripts/import_oeuvre_genres.sh &&
  bash scripts/import_personne_professions.sh &&
  bash scripts/import_evaluations.sh &&
  bash scripts/import_titres_alternatifs.sh &&
  bash scripts/import_episodes.sh &&
  bash scripts/import_participations.sh &&
  bash scripts/import_credits_techniques.sh &&
  bash scripts/import_oeuvres_connues.sh
}
```

Le temps total de chargement est **estimé à environ 4 heures** pour l'ensemble des 12 tables. Cette durée est indicative et dépend des performances de l'ordinateur et du disque.

Remplacement des données :

Nous avons exécuté la commande suivante dans Git Bash :

time bash scripts/remplacer_imdb.sh

Le script s'est arrêté après environ **0,639 seconde** en raison d'un espace disque insuffisant.

```
Benelcadi@DESKTOP-D321M1B UCRT64 ~/Desktop/S3.01-groupe-D (main)
$ time bash scripts/remplacer_imdb.sh
====================================
 REMPLACEMENT COMPLET DES DONNEES IMDb
====================================
Espace libre : 14 Go
ERREUR : espace disque insuffisant.
Il faut au moins 40 Go libres.
La base actuelle n'a pas été modifiée.

real    0m0.639s
user    0m0.045s
sys     0m0.123s
```

Nous estimons que le remplacement complet prendrait **environ 4 à 5 heures**, soit une durée proche de celle de l'importation, car il nécessite de charger à nouveau les données dans une nouvelle base.

Cette durée reste une estimation. La base actuelle a été conservée sans modification.

6. Conclusion :

Ce livrable nous a permis de concevoir une base MariaDB à partir des données IMDb et d'automatiser leur téléchargement et leur importation grâce à des scripts Bash.

Nous avons réussi à remplir les 12 tables et à vérifier leur contenu avec Adminer. Nous avons également étudié les performances des scripts.

La principale difficulté rencontrée a été le manque d'espace disque, qui nous a empêchés de réaliser le remplacement complet des données.