Base de données de films

Contexte

Une base de données contenant un grand nombre d'informations sur la production cinématographique et audiovisuelle est en accès libre. Le but de cette SAÉ sera de construire une application complète permettant de mettre en place ces informations dans un système d'information et de présenter des informations à la communauté d'utilisation, à la fois des informations brutes issues de la base ou des informations calculées à partir de ces données.

Sources

Les données sont disponibles à l'adresse suivante : https://www.imdb.com/interfaces/ .
Il est également recommandé (mais ce n'est pas obligatoire) d'utiliser les sources suivantes pour l'application :

- PHP
- Bootstrap + Bootstrap icons
- JQuery pour la partie présentation si nécessaire
- Un serveur web (par exemple apache2)

Divers logiciels vous seront aussi nécessaires pour rendre vos livrables
Ce document pourra être complété au fur et à mesure de votre avancée.

Livrables

1. Composition de l'équipe, planification de la répartition du rôle de manager, mise en place d'un dépôt de code accessible aux membres de l'équipe et à l'équipe pédagogique (texte, **11 octobre 2026**, rendu collectif) (Compétence 5)
2. Analyse des conditions juridiques d'utilisation des données initiales. La licence d'utilisation est en anglais, le texte rendu doit être en français (format : texte, **18 octobre 2026,** rendu collectif) (Compétence 4 / Compétence 6)
3. Mise en place d'une plateforme de développement avec les logiciels recommandés (format: texte explicatif ; **18 octobre 2026**, rendu collectif) (Compétence 1 / Compétence 3)
4. Présentation sous forme de texte d'un objectif de site qui contient les éléments mentionnés dans le reste de ce document : but, public visé, particularités (format: texte explicatif ; **18 octobre 2026**, rendu collectif ; non évalué).
5. Analyse de la base de données fournie et création de schémas SQL correspondant ; scripts shells de récupération des données les plus récentes et chargement/remplacement dans la base (format : scripts shells ; schémas SQL ; graphiques UML ; indicateurs de performance (temps de chargement, récupération, etc.) ; rendu collectif, **15 novembre 2026**) (Compétence 3 / Compétence 4)
6. Présentation de sources secondaires de données qui pourront être utilisées pour faire de l'agrégation de données (rendu collectif, **15 novembre 2026 ; non évalué)**

7. Création de rapports individuels évolutifs sur le travail réalisé (format : texte mis en page ; à la fin de chaque période de deux semaines, rendu individuel) (Compétence 1 / Compétence 6)
8. Création d'un rapport de management pour la période dont vous allez être responsable détaillant la répartition et la planification des tâches, ainsi que l'évaluation individuelles de ces tâches par le manager (rendu individuel au début de la période suivant la période où un élève remplit le rôle de manager). (Compétence 5 / Compétence 6). **Précisions: à faire avec le logiciel de votre choix (Excel par exemple), inclure des diagrammes de Gantt, des tableaux de suivi, etc.**
9. Création de personas de clients susceptibles d'utiliser le site (**15 novembre 2026** ; rendu individuel) (Compétence 1 / Compétence 5). Une fiche-type de persona est disponible dans le dépôt. Vous ajouterez aussi les user stories correspondantes.
10. Rapport sur trois algorithmes au sein de l'application (approximation d'un nom ; trouver des éléments en commun dans deux listes de façon optimale ; trouver la plus courte chaîne entre deux éléments dans le graphe "a joué dans") (rendu collectif ; **13 décembre 2026, 2 algos ; complété le 17 janvier 2027 pour le troisième**) (Compétence 2)
11. **Prototypage de l'application (tâches à effectuer, user stories, scénarios, design, présentation de prototype avec des logiciels de type Figma, Balsamiq ou autres ; rendu 13 décembre 2026). (Compétence 1)**
12. **Première démonstration de l'application fonctionnelle (semaine du 11 janvier 2027) (Compétence 1 / Compétence 2 / Compétence 4)**
13. Mise en place d'une plateforme de démonstration de l'application (rendu collectif ; **13 février 2027**) (Compétence 3)
14. Prototypage de fusion de données (rendu collectif ; **13 février 2027**) (Compétences 3 et 4, principalement, mais pas exclusivement) : notamment, modification de la base de données nécessaires, algorithmes utilisées, etc.
15. Soutenance de présentation du projet (présentation individuelle ; **semaine du 7 mars 2027**) (Toutes les compétences mais en particulier la 6).
16. **Il sera demandé une démonstration finale de l'application autour de la soutenance ; il est aussi prévu des modalités d'évaluation individuelles.**

Besoins de l'application

Présentation d'information

L'application doit permettre la présentation d'information sur les personnes et les films présents dans les données (attention, certains films sont en fait des séries et ont des épisodes). Lorsque c'est pertinent, il faut pouvoir passer d'une fiche à une autre. Dans un deuxième temps, il vous sera demandé de trouver plusieurs sources secondaires de données cinématographiques, et le responsable du projet vous indiquera au moins une de ces sources qui devra être utilisée pour faire de l'agrégation de données.
Vous présenterez la finalité

Recherche

Il faut pouvoir chercher une personne par son nom, son prénom ou un film par son titre, en recherche simple, et proposer une recherche avancée qui permet de sélectionner par d'autres critères (plage de temps pour la naissance d'une personne ou pour la création d'un film, par exemple). La recherche avancée doit pouvoir permettre de trouver une ressemblance approximative.

Les résultats pourront être triés selon différents critères (en particulier : date, ordre alphabétique, etc.)

Trouver des films ou personnes en commun

Après avoir sélectionné deux films ou deux personnes, trouver les personnes (ou les films) en commun pour les deux. Par exemple, Thierry Lhermitte et Gérard Jugnot ont joués tous les deux dans Fallait Pas, Grosse Fatigue, Le père Noël est une ordure, Les 1001 nuits, Les Bronzés, Les Bronzés font du ski, Les Bronzés 3, Les Secrets professionnels du Dr Apfelglück, Papy fait de la résistance, Trafic d'influence, Vous n'aurez pas l'Alsace et la Lorraine.

Rapprochement de films

On veut pouvoir relier deux films ou personnes par une chaîne de personnes et films la plus courte possible suivant la relation "X a participé au film Y". Par exemple, on peut passer de John Travolta à Harrison Ford en passant par Pulp Fiction, Rosanna Arquette, Le Grand Bleu, Jean Reno, Léon, Natalie Portman, Star Wars III : Revenge of the Sith, Ewan McGregor, Star Wars VII : The Force Awakens, Harrison Ford. Est-ce qu'il y a plus court ?

Notes

Effectif de l'équipe

Le travail se fera en équipes de 4 personnes (5 si nécessaire ; 4 équipes au total). L'équipe pédagogique aura le mot final pour réorganiser les équipes le cas échéant.

Rôle de manager

Le rôle de manager devra être un rôle tournant par période de 2 semaines. Lorsqu'un élève devient manager, il s'occupe de la (re)planification des tâches, de la communication des livrables à l'équipe pédagogique, et de l'évaluation de la complétion des tâches à la fin de la période dont il est responsable. Il transmet son document de gestion d'équipe à la personne suivante (et à l'équipe pédagogique pour évaluation).

Plateforme de développement

Le code doit pouvoir fonctionner à partir d'un dépôt de sources compatible avec git. Le dépôt contiendra un sous-répertoire `livrables` qui contiendra les rendus demandés. Le système d'exploitation de référence est Linux (côté serveur), mais il peut être intéressant de proposer un déploiement sur plusieurs systèmes d'exploitation (notamment en mode développement). Un dépôt de fichiers textes unique dans le moodle permettra de rendre d'une part l'adresse du dépôt git, et d'autre part la liste des membres.

Algorithmes

Trois algorithmes complexes sont requis pour les fonctionnalités de l'application (recherche approximative, éléments communs dans deux listes, plus courte chaîne dans un graphe biparti). Un des livrables concerne les méthodes pour y arriver. Vous analyserez en détail ces algorithmes (avec notamment des jeux d'essais de quelques requêtes) et rendrez cette analyse en plus de votre implémentation du troisième (les deux premiers peuvent être faits directement en SQL, mais si vous choisissez de le faire en PHP, vous donnerez aussi votre implémentation). Dans le cas du SQL, vous analyserez les réglages nécessaires sur les tables et la base.

Utilisation de l'IA, collaborations

Pour ce projet, l'écriture de code par une IA génératrice est strictement interdit. Tous les textes rendus doivent être écrits entièrement par des humains (qui font partie de l'équipe).
Il est possible que certaines tâches demandées soient difficiles, mais ça fait partie du processus. Il est aussi possible que les résultats ne soient pas parfaits, pas complètement possibles, etc. : ça fait partie du processus.
La création de graphismes doit aussi se faire sans IA génératrice, mais l'usage d'éléments graphiques développés par d'autres est possible. Vous ajouterez une liste de ces éléments dans le projet, avec une attribution autant que possible et la licence d'utilisation qui aurait dû faire l'objet d'une acquisition si vous étiez dans un contexte réel et commercial.
Les évaluations individuelles pourront porter sur des morceaux que vous n'avez pas fait personnellement : il est de votre rôle d'avoir une connaissance claire de ce qui a été fait dans tout le projet.

Clarté, esthétique, courtoisie, expression

L'ensemble du projet est soumis aux bonnes règles de communication : vous devez utiliser un langage professionnel, poser des questions claires et donner des réponses claires, travailler sur l'aspect esthétique de votre projet (vous n'êtes pas graphistes, c'est entendu, les attentes de l'équipe pédagogique seront adaptées : vous ferez néanmoins du travail soigné), et vous soignerez aussi orthographe et grammaire (les logiciels d'aide à la correction de la langue sont autorisés, par exemple languagetool ou les outils grammaticaux inclus dans la suite office, tant qu'il ne s'agit pas de réécriture de texte). Vous resterez de plus courtois autant avec l'équipe pédagogique qu'avec vos collègues ou concurrents.

Sécurité

La sécurité de l'application, de la base de données et de l'infrastructure doit être prise en compte dès la conception et tout au long du projet. Elle vise à garantir :

- la confidentialité : seules les personnes autorisées accèdent aux données et fonctionnalités ;
- l'intégrité : les données ne sont pas altérées de manière non contrôlée ;
- la disponibilité : l'application reste accessible et fonctionnelle ;
- la traçabilité : les actions importantes peuvent être analysées en cas d'incident.

La conception fonctionnelle du site reste ouverte, mais les mesures de sécurité décrites ci-dessous constituent un socle minimal attendu. Les choix techniques devront être documentés et justifiés.

Principes généraux de la sécurité des applications

- Moindre privilège : chaque composant (utilisateur, script, compte SGBD) ne dispose que des droits strictement nécessaires.
- Validation des entrées / échappement des sorties : ne jamais faire confiance aux données reçues, qu'elles viennent de l'utilisateur, de l'URL ou de sources externes comme IMDb (comme expliqué dans le cours R301).
- Documentation : expliquer les choix de sécurité dans les livrables et les rapports.

Sécurité de la base de données

- Utiliser un compte SGBD dédié à l'application, avec des droits limités (SELECT, INSERT, UPDATE, DELETE selon les besoins). Ne jamais utiliser le compte root ou l'équivalent administrateur dans le code de l'application.
- Requêtes préparées obligatoires (PDO) pour lutter contre les injections SQL. Les concaténations de chaînes SQL sont proscrites.
- Définir des contraintes d'intégrité : clés primaires, clés étrangères, unicité, types de données.
- Indexer les colonnes utilisées dans les recherches et les jointures, sans dégrader les performances d'écriture.
- Mettre en place des sauvegardes régulières de la base et tester la restauration.
- Si des données utilisateurs sont stockées (comptes, préférences), prévoir un chiffrement ou un hachage adapté et limiter la collecte au strict nécessaire.

Sécurité de l'application web

- Authentification : si des comptes sont créés, stocker les mots de passe hachés (par exemple avec password_hash()/password_verify()). Ne jamais stocker de mot de passe en clair.
- Sessions : configurer les cookies de session avec HttpOnly, Secure (en production) et SameSite. Régénérer l'identifiant de session après connexion (session_regenerate_id). Prévoir une déconnexion et une expiration.

-
- Contrôle d'accès : vérifier les droits à chaque page sensible, côté serveur. Ne pas se contenter de masquer les liens dans l'interface.
- Formulaires : protéger contre les attaques CSRF avec un jeton unique par session.
- XSS : échapper toutes les sorties affichées avec htmlspecialchars() ou une bibliothèque équivalente. Ne pas injecter de HTML non contrôlé.
- Validation des entrées : valider côté serveur (type, longueur, format) et côté client pour le confort. Ne jamais considérer la validation client comme suffisante.
- Gestion des erreurs : afficher des messages génériques à l'utilisateur, journaliser les détails côté serveur. Ne pas exposer les traces PHP, les requêtes SQL ou les chemins internes (en production).
- En-têtes HTTP : ajouter au minimum X-Content-Type-Options, X-Frame-Options, Content-Security-Policy si possible (cherchez ces mots)

Sécurité des données et vie privée

Les données IMDb sont publiques, mais leur licence d'utilisation doit normalement être respectée. L'analyse juridique demandée dans le livrable 2 devra préciser les droits et obligations, et les droits qu'il faudrait négocier avec IMDB pour votre version du projet.
NB: dans le cadre de ce projet à visée pédagogique, il n'y aura pas d'achat de licence pour faire des choses interdites par les données ouvertes. Toutefois, on peut imaginer qu'un projet commercial paierait pour avoir des droits plus étendus, vous pouvez donc concevoir votre site web comme si vous pouviez payer des droits plus étendus.

- Pour éviter toute complexité liée au RGPD, il est recommandé de ne pas collecter de données personnelles (pas de compte utilisateur avec email, pas de formulaire de contact, etc.).
- Si des données personnelles sont malgré tout collectées, vous devez être conscients que vous n'êtes pas en conformité RGPD et le signaler dans vos rapports. Dans ce cadre pédagogique, c'est toléré, mais ce ne serait pas acceptable en production.

Sécurité de l'infrastructure et du déploiement

Le serveur de référence est Linux. Maintenir le système et les logiciels à jour.
Configurer le serveur web (Apache, Nginx) pour :

- désactiver l'affichage des répertoires ;
- limiter les permissions des fichiers et répertoires ;
- séparer les environnements de développement et de production.
- Ne jamais versionner de secrets (mots de passe, clés API, identifiants SGBD) dans le dépôt Git. Utiliser des variables d'environnement ou un fichier .env ignoré.
- Restreindre l'accès SSH (clés, pas de mot de passe simple) et limiter les ports ouverts.
- Faire des revues de code entre membres de l'équipe, en particulier sur les parties sensibles (authentification, requêtes SQL, formulaires).

Tests et recette sécurité

Avant la démonstration finale, l'équipe devra tester au minimum :

- l'injection SQL sur les formulaires de recherche et de connexion ;

- les failles XSS sur les champs affichés ;
- la gestion des sessions et des droits ;
- l’exposition des erreurs en production ;
- l’accès direct aux fichiers sensibles.

Les failles corrigées et les mesures prises devront être documentées.